

RELATÓRIO DE ANÁLISE DE DADOS: SPOTIFY TRACKS

Disciplina: Python Para Análise de Dados

Aluno: João Vitor Casemiro de Lima

Data: 17/05/2026

1. Introdução

Este relatório apresenta os resultados do processo de extração, limpeza, transformação e análise exploratória do Spotify Tracks Dataset. O conjunto de dados original possuía cerca de 114.000 registros, contendo informações sobre músicas, artistas, gêneros e métricas de áudio extraídas via API do Spotify (plataforma para reprodução de músicas). As bibliotecas utilizadas para este projeto foram **Pandas**, **Numpy** e **Matplotlib**.

2. Ingestão, Qualidade dos Dados e ETL

Após a ingestão do arquivo original bruto (dataset.csv), foi realizado um diagnóstico de qualidade que embasou as seguintes decisões de limpeza e transformação:

Tratamento de Valores Nulos: O diagnóstico apontou apenas 1 única linha contendo valores nulos nas colunas artists e track_name. Decidiu-se pela remoção dessa linha (dropna), visto que a ausência de identificação da música inviabiliza a análise e o impacto no volume de dados é estatisticamente nulo.

Tratamento de Duplicatas: Identificamos que o dataset repetia as mesmas músicas (mesmo track_id) apenas para classificá-las em gêneros musicais diferentes. Para evitar que músicas repetidas distorcessem a média de popularidade geral, as duplicatas baseadas na coluna track_id foram removidas, mantendo-se apenas a primeira ocorrência.

Transformações (Limpeza): A coluna Unnamed: 0, que representava um índice exportado indevidamente da fonte original, foi excluída por não agregar valor analítico.

Derivação de Novas Variáveis: A duração das músicas, originalmente na coluna duration_ms (milissegundos), foi dividida por 60.000 para criar a coluna duration_min (minutos), facilitando a leitura.


Utilizando a biblioteca Numpy (np.where), derivamos uma variável categórica chamada categoria_duracao, classificando as músicas como "Longa" (se duration_min > 5.0) ou "Padrão" (caso contrário).

3. Análise Exploratória de Dados

Com o dataset limpo, definimos 3 perguntas de pesquisa para compreender melhor o comportamento das músicas na plataforma.

Pergunta 1: Quais são os 10 gêneros musicais mais populares e quais os menos populares?


Agrupamos os dados por gênero (track_genre) e calculamos a média matemática da métrica de popularidade (Métrica definida pelo Spotfy que vai de 0 a 100). O resultado foi ordenado de forma decrescente no primeiro gráfico, para mostrar os 10 gêneros mais populares, e de forma decrescente para os gêneros menos populares.



Conclusão: O gráfico demonstra que gêneros massificados, como Pop, K-Pop e Hip-Hop, dominam a plataforma, apresentando as maiores médias de popularidade (acima de 50 pontos), enquanto gêneros de nicho ocupam as posições inferiores, como, Iraniano e Romance.


Pergunta 2: Músicas com conteúdo explícito são mais populares que músicas sem conteúdo explícito?

Comparamos a média de popularidade agrupando a variável booleana (explicit).



Conclusão: A análise indica que músicas classificadas como explícitas possuem, em média, um índice de popularidade superior às músicas não explícitas. Isso pode refletir o perfil do público majoritário da plataforma e o sucesso comercial de gêneros urbanos que frequentemente utilizam linguagem explícita.

Pergunta 3: Qual é o tempo de duração padrão da maioria das músicas no Spotify? Utilizamos um gráfico de barras para comparar a distribuição da nova variável derivada (duration_min) filtrando músicas de até 10 minutos para evitar distorções visuais por podcasts



Conclusão: O gráfico mostra uma distribuição concentrada (formato de sino) indicando que a grande maioria das músicas produzidas e ouvidas no Spotify segue um padrão comercial rigoroso de duração, concentrando-se entre 2,5 e 4 minutos.

Conclusão Final

O processo de ETL foi fundamental para garantir a integridade da análise, reduzindo quase 25 mil registros duplicados que teriam enviesado os resultados. A Análise Exploratória revelou que o sucesso comercial no Spotify (alta popularidade), e mostra a predominância de gêneros pop/urbanos, aceitação de conteúdo explícito e durações padronizadas abaixo de 4 minutos.